

Deep Learning como un Problema de Control Óptimo

Maximiliano Valladares G., Nicolás Fuenzalida S., Diego Acuña S.

Universidad de Chile
Departamento de Ingeniería Matemática

Resumen

Este trabajo presenta una implementación de redes neuronales tipo ResNet^[1] interpretadas como problemas de control óptimo para resolver un problema de clasificación. Se desarrollaron y resolvieron ecuaciones adjuntas para minimizar el Hamiltoniano asociado. Los resultados muestran cómo estas arquitecturas pueden realizar clasificación de datos sintéticos con excelente precisión.

Introducción

El problema de clasificación es fundamental en el aprendizaje de máquinas y el *deep learning*. Consiste en asignar a cada dato $x \in \mathbb{R}^n$ una etiqueta $c \in \{c_0, c_1, \dots, c_{K-1}\}$. El objetivo es aprender una función $g : \mathbb{R}^n \rightarrow \{c_0, c_1, \dots, c_{K-1}\}$ parametrizada por pesos y sesgos, que prediga correctamente las etiquetas minimizando la función de costo:

$$J(u, W, \mu) = \frac{1}{2} \sum_{i=1}^m |\mathcal{C}(Wh(x_i; u) + \mu) - c_i|, \quad (1)$$

donde $\mathcal{C} : \mathbb{R} \rightarrow \{c_0, c_1\}$ es la función de hipótesis, $h(x_i; u)$ es una transformación parametrizada, W es un vector de pesos y μ es un sesgo.

Abordamos este problema desde la perspectiva del control óptimo, utilizando la arquitectura de Redes Neuronales Residuales (*ResNet*), que se interpreta como la discretización en el tiempo de un sistema dinámico controlado, en donde el paso entre dos capas consecutivas se puede expresar como:

$$y^{[j+1]} = y^{[j]} + \Delta t f(y^{[j]}, u^{[j]}), \quad j = 0, \dots, N-1, \quad (2)$$

donde $y^{[j]}$ representa el estado en la capa j , Δt es un paso temporal fijo, y $u^{[j]} = (K^{[j]}, \beta^{[j]})$ son los parámetros del modelo (pesos y sesgos).

Planteamiento y Metodología

Se considerará una discretización del tiempo para la resolución del problema. Para ello, si N es el número de capas de la red neuronal, las variables de estado y el control quedarán expresadas respectivamente por:

$$y = (y^{[0]}, \dots, y^{[N-1]}) \text{ donde cada } y^{[i]} = (y_1^{[i]}, \dots, y_n^{[i]}) \quad (3)$$

Para plantear este problema como uno de control óptimo, se considerará el control $u = (K, \beta)$, donde $K \in \mathbb{R}^{n \times n}$ es la matriz de pesos asociada al clasificador g , y $\beta \in \mathbb{R}^n$ un vector de sesgos asociados al mismo clasificador. Luego, el control tras la discretización quedará expresado por:

$$u = (u^{[0]}, \dots, u^{[N-1]}) \text{ donde cada } u^{[i]} = (K^{[i]}, \beta^{[i]}) \quad (4)$$

Luego, planteando el problema como uno de minimización de la función de costos con las variables discretizadas, y considerando la estructura ResNet que toma la dinámica del problema como $\dot{y} = f(y, u) = \sigma(Ky + \beta)$, el problema tendrá asociado su respectivo pre-Hamiltoniano dado por

$$H(y, u, p) = p^\top \sigma(Ky + \beta) \quad (5)$$

Finalmente, por el principio de Pontryagin, las dinámicas discretizadas de las variables de estado y adjuntas, estarán dadas respectivamente por:

$$\begin{aligned} y^{[j+1]} &= y^{[j]} + \Delta t f(y^{[j]}, u^{[j]}), \\ p^{[j+1]} &= p^{[j]} - \Delta t (\partial_y f(y^{[j]}, u^{[j]}))^\top p^{[j+1]} \end{aligned} \quad (6)$$

Así, teniendo estas dinámicas definidas, se puede modelar aquel problema de minimización a través de la librería **JuMP** de **Julia**, considerando como restricciones todas las dinámicas del problema, y sus casos bordes.

Resultados y Discusión

Tras implementar el problema de minimización a través de **JuMP** considerando una red neuronal de 35 capas con 50 muestras sintéticas (es decir, generadas a mano aleatoriamente), se puede observar la siguiente evolución del espacio de características a través del paso de cada capa de la red:




Figura 1: Evolución del Espacio de Características

Para esto se consideró función de costos sin una regularización sobre el control, puesto que el costo computacional aumentaba significativamente, demorando horas en ejecutar el código, sin embargo, sin considerar una regularización sobre el control, el código demoró 23 minutos en ejecutar, que para 35 capas, resultó hacer una separación de las clases bastante efectiva, sin considerar el único outlier observable en la última capa. Se estima que considerando a lo más 50 capas, la clasificación debería tener una precisión enorme. Cabe mencionar que la minimización mediante la librería **JuMP** tomó 437 iteraciones, obteniendo que el valor de la función de costos al final era igual a 0.

Conclusiones

Con este proyecto se puede concluir que el problema de clasificación se puede abordar gracias a la implementación de redes neuronales con la arquitectura ResNet, abordando el caso binario. Se logró un error residual muy bajo gracias a la minimización del Hamiltoniano del sistema asociado, y gráficamente se puede observar cómo las capas intermedias de ResNet transforman los datos, moviendo los puntos de las clases hacia regiones bien separadas en el espacio de característica, permitiendo una clasificación exitosa y efectiva.

Referencias

- [1] M. Benning, E. Celledoni, M. J. Ehrhardt, B. Owren, and C.-B. Schönlieb, "Deep learning as optimal control problems: models and numerical methods," *arXiv preprint arXiv:1904.05657*, 2019.